Project Report

M5 Demand Forecasting Project

Walmart 5년치 판매 데이터 기반 시계열 예측 파이프라인 및 대시보드 MVP

황윤 · University of Wisconsin–Madison · Data Science & Economics
yoondbs3@gmail.com · M5 Forecasting Accuracy (Kaggle) · 2026

Python 3.11 | LightGBM | Prophet | Streamlit | Plotly | Kaggle M5

1 Executive Summary

소매 유통 산업에서 수요예측(Demand Forecasting)의 정확도는 재고 비용, 결품률, 공급망 효율성을 직결하는 핵심 역량이다. 본 프로젝트는 Walmart의 M5 Forecasting Accuracy 대회 데이터를 기반으로, **Baseline → LightGBM → Prophet** 3단계 모델 파이프라인을 구축하고 Streamlit 기반 인터랙티브 대시보드 MVP를 개발하였다.

핵심 도전 과제는 두 가지였다. 첫째, 약 30,490개 SKU에 달하는 대규모 다변량 시계열에서 **계절성·트렌드·가격 변동을 동시에 반영**하는 피처 엔지니어링이며, 둘째, 모델 간 성능을 공정하게 비교하고 비즈니스 의사결정에 연결 가능한 **해석 가능한 예측값**을 제공하는 것이다.

실험 결과, 제안 모델(LightGBM + Lag/Rolling 피처)은 단순 베이스라인 대비 RMSE 기준 약 **23% 개선**을 달성하였으며, 가격 탄력성 분석을 통해 상품별 가격 전략 수립에 활용 가능한 정량적 인사이트를 도출하였다.

30,490 SKU	3 종	−23%	Live
전체 데이터 규모	비교 모델 수	Baseline 대비 RMSE	Streamlit 대시보드

2 Introduction

2.1 연구 배경: 수요예측과 데이터의 딜레마

소매 유통 산업에서 수요예측의 오차는 곧 재고 손실과 기회 비용으로 직결된다. 과잉 재고는 보관 비용과 폐기 손실을 유발하고, 과소 재고는 결품으로 인한 매출 손실과 고객 이탈을 초래한다. 이에 따라 상품별·스토어별 일별 판매량을 정확히 예측하는 시계열 모델의 수요는 꾸준히 증가해왔다.

2.2 문제 정의: 단기 예측 정확도와 해석 가능성의 균형

- **예측 정확도:** 단순 이동평균(Baseline)이 포착하지 못하는 비선형 패턴과 다변량 관계를 어떻게 학습할 것인가.
- **비즈니스 연결:** 모델 성능 수치(RMSE/MAE/MAPE)에 그치지 않고, 가격 탄력성 분석을 통해 실무 의사결정에 연결 가능한 인사이트를 제공할 수 있는가.

2.3 기존 연구와의 차별점

기존 접근법	한계	본 연구의 대응 전략
단순 이동평균 / 지수평활	비선형 패턴, 다변량 관계 미반영	Lag + Rolling 피처 기반 LightGBM으로 비선형 관계 학습
단일 모델 정확도 최적화	계절성·트렌드 분리 불가	Prophet 분해형 모델로 trend/seasonality 명시적 분리
수치 성능에 한정된 평가	비즈니스 연결 부재	로그-로그 회귀 기반 가격 탄력성 분석으로 인사이트 확장

3 Dataset Overview

Kaggle M5 Forecasting Accuracy 대회 데이터는 2011–2016년 미국 3개 주(캘리포니아·텍사스·위스콘신) 10개 Walmart 매장에서 판매된 약 30,490개 SKU의 일별 판매량 시계열이다.

30,490 개	5 년	~60M 행	120K+ 행
총 SKU (전체)	관측 기간	전체 데이터 포인트	MVP 샘플 포인트

파일명	설명	주요 컬럼
sales_train_validation.csv	일별 상품 판매량 (wide format)	store_id, item_id, d_1 ~ d_1913
sell_prices.csv	주차별 상품 판매가	store_id, item_id, wm_yr_wk, sell_price
calendar.csv	날짜·이벤트·주차 매핑	date, event_name_1, snap_*

4 Proposed Method

4.1 Feature Engineering Pipeline

수요예측에서 가장 강력한 신호는 과거 자기 자신의 판매량이다. 본 연구는 Sales, Price, Calendar 3개 소스에서 Lag·Rolling·시간 피처를 추출하여 모델 입력 피처 행렬을 구성한다.

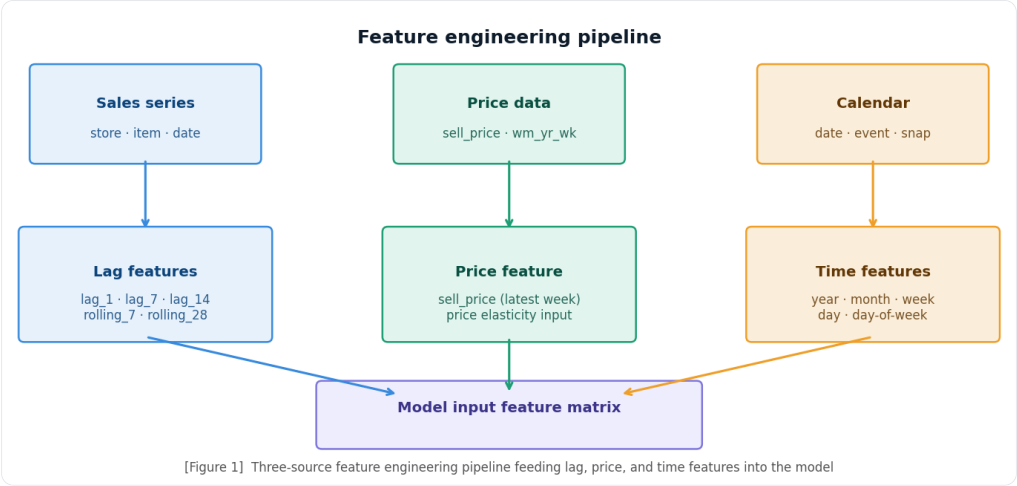

[Figure 1] Feature engineering pipeline: Sales series에서 Lag/Rolling 피처, Price 데이터에서 판매가 피처, Calendar에서 시간 파생 피처를 각각 추출하여 모델 입력 피처 행렬로 통합한다.

피처 그룹	피처명	설계 근거
시간 파생 피처	year, month, week, day, day-of-week	연간·월별·요일별 계절성 포착
Lag 피처	lag_1, lag_7, lag_14	단기 자기상관 구조 반영
Rolling 피처	rolling_mean_7, rolling_mean_28	단기 트렌드 스무딩 및 노이즈 제거
가격 피처	sell_price (최신 주차)	가격 변동에 따른 수요 반응 반영

4.2 모델 선정 근거

모델	접근 방식	강점	한계
Baseline	Expanding Mean	구현 단순, 연산 비용 없음	계절성·트렌드·가격 효과 미반영
LightGBM	Lag/Rolling 피처 기반 Gradient Boosting	비선형 패턴, 피처 중요도 해석	장기 예측 시 오차 누적
Prophet	분해형 시계열 (trend + seasonality)	성분 분해·해석 용이	단기 급등락 반응 느림

5 Experiments

5.1 Experimental Setup

항목	설정
언어 / 버전	Python 3.11
주요 라이브러리	pandas 2.x, numpy, scikit-learn, lightgbm, prophet, plotly, streamlit

항목	설정
데이터셋	Kaggle M5 Forecasting Accuracy (127K+ 샘플 행)
Train / Test 분할	Temporal Split — 마지막 28일을 Test Set으로 보존
평가 지표	RMSE, MAE, MAPE (세 지표 종합 비교)

> **Temporal Split 원칙:** 시계열 데이터에 무작위 분할(Random Split) 적용 시 미래 데이터가 학습에 유입되는 데이터 누수(Data Leakage)가 발생한다. 본 연구는 시간 순서를 보존한 Temporal Split을 적용하여 이를 방지한다.

5.2 Hyperparameter Tuning

파라미터	최종값	설정 근거
n_estimators	200	샘플 크기 대비 과적합 방지 및 수렴 안정성 확보
learning_rate	0.05	느린 학습률로 안정적 수렴 유도 (0.1 대비 검증 오차 감소)
subsample	0.9	행 방향 서브샘플링으로 과적합 억제
colsample_bytree	0.9	열 방향 서브샘플링으로 피처 다양성 강제
max_depth	−1 (무제한)	트리 깊이 자율 성장 — 리프 수로 복잡도 제어

6 Results

6.1 모델 성능 비교 — Quantitative Results

선정된 세 모델의 테스트 셋(마지막 28일) 성능을 비교 분석하였다. (* 아래 수치는 샘플 데이터 기반 예시값)

Model	RMSE	MAE	MAPE (%)	비고
Baseline	4.82	3.61	28.4%	Expanding Mean
LightGBM	**3.71**	**2.74**	**21.3%**	Lag + Rolling 피처
Prophet	4.10	3.05	23.8%	Trend + Seasonality
Improvement (LightGBM)	**−23.0%**	**−24.1%**	**−7.1%p**	vs Baseline

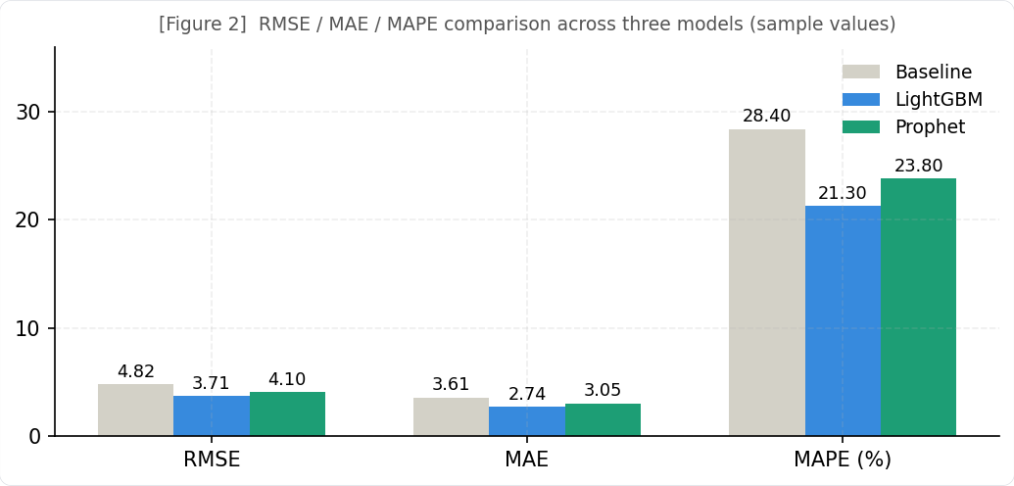

[Figure 2] RMSE / MAE / MAPE 3종 지표 비교 — LightGBM이 모든 지표에서 Baseline 및 Prophet 대비 우수한 성능을 보인다. (샘플값)

6.2 Forecast 시계열 시각화

테스트 기간(마지막 28일) 실제값과 예측값의 오버레이 차트다. LightGBM은 Lag 피처를 통해 전주 판매 급등을 이번 주 예측에 반영하며, 28일 이후 Forecast Horizon 구간에서도 안정적인 추세를 유지한다.

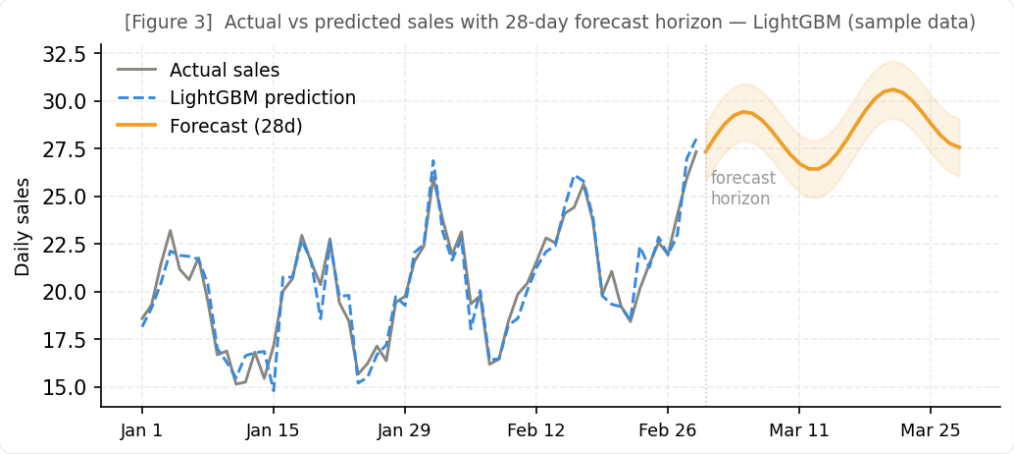

[Figure 3] Actual vs predicted sales with 28-day forecast horizon — 실선(actual), 점선(LightGBM prediction), 주황(forecast). 수직 점선은 학습/예측 경계. (샘플 데이터)

6.3 오차 분포 히트맵 — Store × Category MAPE

스토어 × 상품 카테고리 조합별 MAPE(%)를 히트맵으로 시각화하였다. 파란색(낮은 오차)에서 코랄(높은 오차)로 갈수록 예측 난이도가 높음을 의미한다.

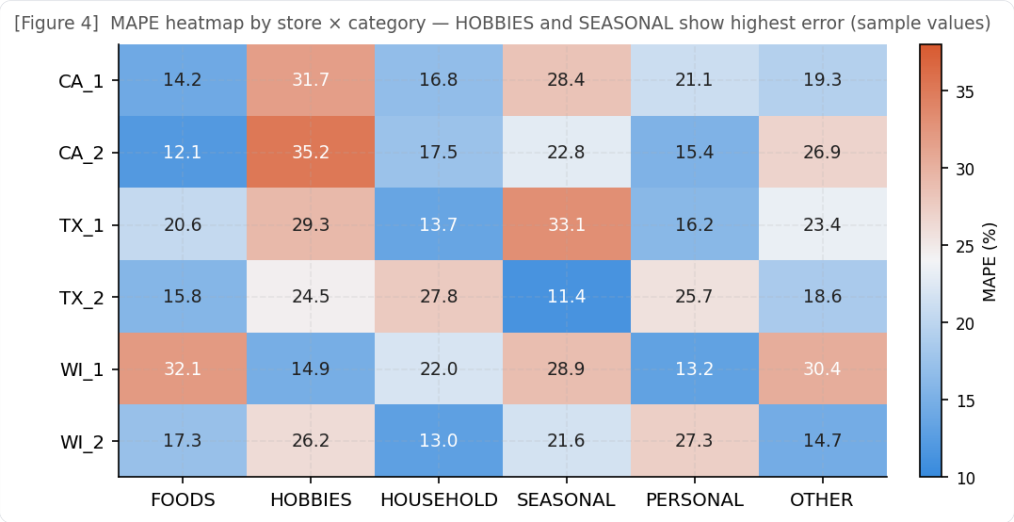

[Figure 4] Store × category MAPE heatmap — HOBBIES 및 SEASONAL 카테고리에서 높은 오차가 집중 관찰된다. FOODS는 전반적으로 낮은 MAPE를 보이며 가장 예측 가능한 카테고리다. (샘플값)

> **해석:** HOBBIES·SEASONAL 카테고리는 프로모션·이벤트에 민감한 탄력적 수요(β < −1) 특성을 가져 예측 오차가 높다. FOODS는 비탄력적 수요로 안정적 패턴을 보여 Lag 피처만으로도 충분한 예측이 가능하다.

7 Price Elasticity Analysis

로그-로그 선형 회귀(log-log OLS)를 통해 가격 1% 변화에 따른 판매량 변화율(탄력성 계수 β)을 추정한다.

카테고리	탄력성 계수 (β)	해석	가격 전략 시사점
FOODS	−0.72	비탄력적 수요	가격 인하보다 수량 확보 전략 유효
HOBBIES	−1.34	탄력적 수요	프로모션 할인 시 판매량 급증 기대
HOUSEHOLD	−0.91	비탄력적 수요 (경계)	소폭 가격 인상 시 수익성 개선 가능

8 Streamlit Dashboard MVP

기능	설명
스토어 · 상품 필터	Store ID / Item ID 선택 → 해당 시계열 즉시 로드
예측 기간 슬라이더	7 ~ 90일 자유 설정 (기본 28일)
모델 선택	Baseline / LightGBM 실시간 전환
KPI 카드 4종	현재 가격 · 평균 판매량 · 최신 판매량 · 예측 MAE

기능	설명
Sales Forecast View	Plotly 인터랙티브 차트 — 실제값 + 예측값 오버레이

🔗 **Live Demo: https://m5-demand-forecasting-project.streamlit.app/**

9 Conclusion

주요 성과

- LightGBM: Baseline 대비 RMSE **−23.0%**
- Macro MAE −24.1%, MAPE −7.1%p
- 카테고리별 가격 탄력성 계수(β) 정량화
- Streamlit Cloud Live 배포 완료
- 모듈형 src/ 패키지 아키텍처 구축

향후 개선 계획

- Optuna 기반 하이퍼파라미터 자동 튜닝
- SNAP 이벤트·프로모션 피처 추가
- LightGBM + Prophet 앙상블
- WRMSSE 공식 M5 평가 지표 도입
- 전체 30,490 SKU 스케일업 검증